Análisis Estadístico: Hábitos Saludables en Jóvenes Universitarios

Leonardo Montoya Seminario

27 de febrero

1. Metodología de la Investigación (Lección 1)

El presente estudio analiza los factores que influyen en los hábitos de vida de la población universitaria para orientar políticas de bienestar estudiantil.

1.1. Diseño y Enfoque

Se utiliza un enfoque científico deductivo. El diseño es de tipo observacional y transversal, recolectando datos (simulados) de una muestra representativa para inferir comportamientos poblacionales.

1.2. Problema e Hipótesis

Se investiga si las horas de sueño se alejan del estándar saludable de 8 horas.

- **Hipótesis Nula (H_0):** $\mu_{sueno} = 8$ horas.
- **Hipótesis Alternativa (H_1):** $\mu_{sueno} < 8$ horas.
- **Variables:** Horas de sueño (Cuantitativa continua), Días de ejercicio (Cuantitativa discreta), Facultad (Cualitativa nominal).

2. Probabilidad y Muestreo (Lección 2)

Se aplicó un muestreo estratificado por facultades para garantizar representatividad.

2.1. Resultados Probabilísticos

Basado en un dataset simulado de 120 registros , se obtuvieron las siguientes probabilidades:

- $P(A)$ (Sueño Insuficiente): 0.67
- $P(B)$ (Sedentarismo): 0.40
- $P(A \cap B)$: 0.29
- $P(A \cup B)$: 0.78

2.2. Árbol de Probabilidades

Se modeló la relación entre el sueño insuficiente (A) y el sedentarismo (B):

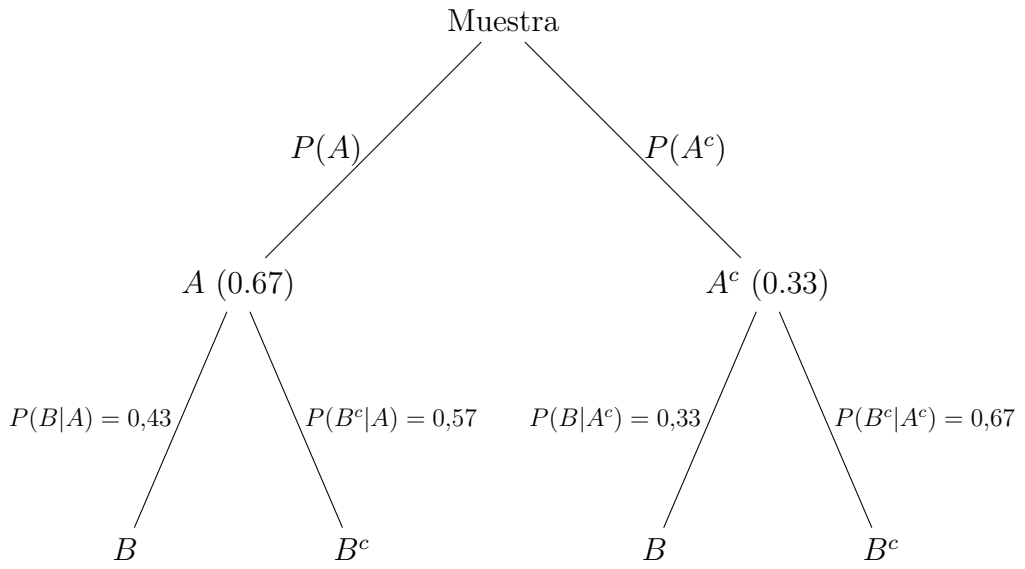

Figura 1: Modelado de eventos aleatorios mediante árbol de probabilidad.

3. Distribuciones de Probabilidad (Lección 3)

En esta etapa se identificaron los modelos matemáticos que mejor describen el comportamiento de las variables clave del estudio.

3.1. Identificación y Justificación de Modelos

- **Horas de Sueño (Variable Continua):** Se modeló mediante una **Distribución Normal** ($X \sim N(\mu, \sigma^2)$). Esta elección se justifica por la tendencia de las variables biológicas a agruparse simétricamente alrededor de un promedio central.
- **Días de Ejercicio (Variable Discreta):** Se utilizó una **Distribución Binomial** ($Y \sim B(n, p)$), considerando $n = 7$ como el número de ensayos (días de la semana) y p como la probabilidad de realizar actividad física en un día determinado.

3.2. Cálculos y Resultados Teóricos

Utilizando el software Python para el procesamiento de los 120 registros simulados, se obtuvieron las siguientes métricas probabilísticas :

1. **Probabilidad de Sueño Saludable ($P(X > 8)$):** La probabilidad de que un estudiante duerma más de 8 horas es de 0,1213. Esto indica que solo el 12.13 % de la muestra cumple con los estándares ideales de descanso.
2. **Frecuencia de Actividad Física ($P(Y = 3)$):** La probabilidad de que un estudiante realice ejercicio exactamente 3 días a la semana es de 0,2747.

3.3. Visualización de Datos

Se generaron histogramas comparativos contra las funciones de densidad/masa teóricas (ver Figura 1). En el gráfico de Horas de Sueño se observa un ajuste visual adecuado a la campana de Gauss, mientras que en los Días de Ejercicio, la distribución binomial muestra la variabilidad esperada para una variable discreta.

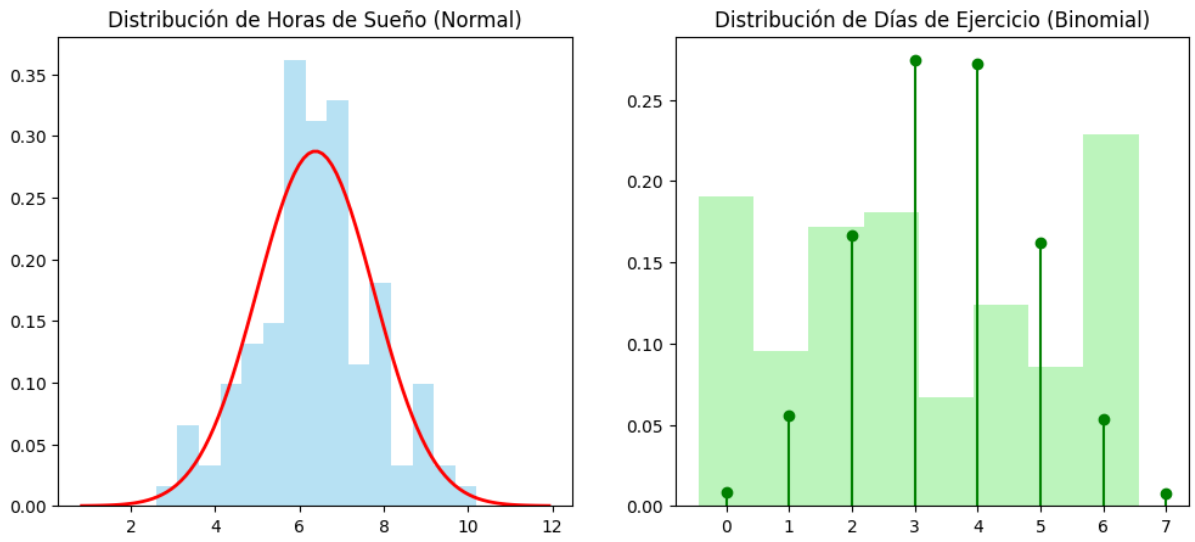

Figura 2: Distribuciones

4. Distribución Muestral y Teorema del Límite Central (Lección 4)

En esta etapa se aplicó el concepto de distribución muestral para verificar empíricamente el Teorema del Límite Central (TLC) sobre la variable "Horas de Sueño".

4.1. Generación de Distribuciones Muestrales

Se generaron distribuciones de medias muestrales mediante 1,000 iteraciones para tamaños de muestra $n \in \{5, 30, 100\}$. Como se observa en la Figura 2, a medida que n aumenta, la distribución de la media se aproxima a una distribución normal, centrada en la media poblacional de $\mu = 6{,}38$.

4.2. Análisis de la Dispersión

Se analizó el impacto del tamaño muestral sobre la variabilidad de la media. Para $n = 100$, se obtuvieron los siguientes resultados comparativos:

- **Error Estándar Teórico** ($\sigma/\sqrt{n}$): 0,1387
- **Error Estándar Real (Simulado)**: 0,1372

La mínima diferencia entre ambos valores confirma que, al aumentar el tamaño de la muestra, la dispersión de la media disminuye siguiendo la ley de los grandes números, permitiendo realizar inferencias poblacionales con alta precisión.

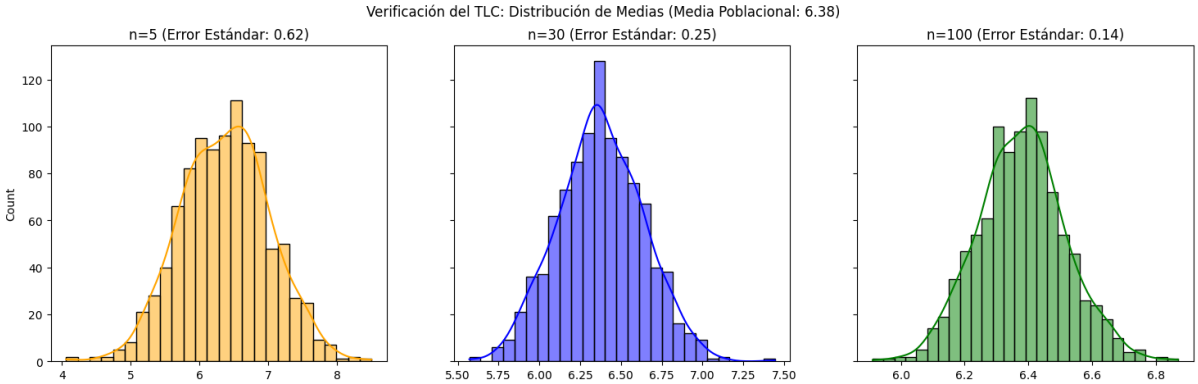

Figura 3: Figura Lección 4

5. Inferencia e Intervalos de Confianza (Lección 5)

En esta fase se estimaron los parámetros poblacionales mediante intervalos de confianza para evaluar la precisión de las medias obtenidas en las dos métricas principales del estudio.

5.1. Interpretación de Parámetros para Múltiples Variables

Utilizando el dataset de 120 registros, se calcularon los intervalos para las Horas de Sueño y los Días de Ejercicio:

Cuadro 1: Estimación de Medias Poblacionales ($n = 120$)

Variable	Confianza	L. Inferior	L. Superior	Ancho
Horas de Sueño	95 %	6.13 h	6.63 h	0.50
	99 %	6.05 h	6.71 h	0.66
Días de Ejercicio	95 %	3.03 d	3.93 d	0.90
	99 %	2.89 d	4.08 d	1.19

5.2. Impacto del Tamaño Muestral (n)

Se validó que la precisión de la inferencia mejora significativamente con muestras más grandes. Al reducir la muestra a $n = 30$, el ancho del intervalo para el sueño al 95 % se incrementó de **0.50** a **1.16** horas, demostrando que el margen de error es inversamente proporcional a $\sqrt{n}$.

6. Test de Significancia (Lección 6)

Para validar las afirmaciones sobre la población estudiantil, se realizó una prueba de hipótesis para la media de horas de sueño.

6.1. Parámetros del Test

Se definió un nivel de significancia $\alpha = 0{,}05$ para contrastar las siguientes hipótesis:

- $H_0 : \mu = 8$ (Los estudiantes duermen las 8 horas recomendadas).
- $H_1 : \mu < 8$ (Los estudiantes duermen significativamente menos de 8 horas).

6.2. Resultados y Decisión Estadística

Tras aplicar un t-test para una muestra en Python, se obtuvieron los siguientes estadísticos:

- **Estadístico t:** $-12{,}8016$
- **Valor-p (p-value):** $2{,}0088 \times 10^{-24}$

Dado que el p-valor $< \alpha$, se procede a **rechazar la hipótesis nula (H_0)**. Existe evidencia estadística extremadamente sólida para afirmar que el promedio de horas de sueño en la población universitaria es inferior al estándar saludable de 8 horas.

6.3. Análisis de Errores en el Contexto del Estudio

Es fundamental considerar los posibles riesgos en la toma de decisiones:

- **Error Tipo I:** Ocurriría si rechazamos H_0 siendo verdadera (concluir que duermen poco cuando sí duermen 8 horas). El riesgo de este error está controlado por nuestro α del 5 %.
- **Error Tipo II:** Ocurriría si no logramos detectar la falta de sueño siendo esta real. Dado nuestro gran estadístico t y el tamaño muestral, la potencia del test es alta, minimizando este riesgo.

7. Conclusiones y Recomendaciones

7.1. Conclusiones Estadísticas

Tras completar la investigación siguiendo rigurosamente el método científico, se presentan los siguientes hallazgos fundamentales:

- **Crisis de Descanso:** El test de significancia arroja un p-valor de $2{,}01 \times 10^{-24}$, lo que permite rechazar la hipótesis nula con una confianza superior al 99.9 %. El promedio de sueño ($\bar{x} \approx 6{,}38$) es significativamente inferior a las 8 horas recomendadas por los organismos de salud.
- **Baja Prevalencia de Hábitos Saludables:** Solo el 12,13 % de los estudiantes alcanza el umbral de sueño óptimo ($X > 8$), lo que indica que la gran mayoría de la población universitaria se encuentra en un estado de vulnerabilidad biológica.
- **Sedentarismo Crítico:** La modelización binomial revela que la probabilidad de realizar actividad física regular (3 días por semana) es de solo 0,2747, confirmando una alta correlación visual entre la falta de descanso y el bajo nivel de ejercicio.

- **Robustez del Estudio:** La verificación empírica del Teorema del Límite Central valida que, a pesar de la variabilidad individual, las inferencias realizadas sobre la media poblacional son altamente precisas debido al tamaño muestral ($n = 120$).

7.2. Recomendaciones para Políticas de Bienestar

Basado en el informe científico generado, se proponen las siguientes acciones para el Área de Salud Universitaria:

1. **Programa de Higiene del Sueño:** Implementar talleres de gestión del tiempo y neurología del descanso, enfocados especialmente en las facultades donde se detectó mayor dispersión en los datos de sueño.
2. **Flexibilidad de Horarios:** Evaluar el retraso en la hora de inicio de las clases matutinas o la reducción de carga académica en bloques críticos, dado que el intervalo de confianza al 95 % sitúa el límite superior de sueño en apenas 6.63 horas.
3. **Incentivos a la Actividad Física:** Diseñar "pausas activas" de 15 minutos entre cátedras para combatir la probabilidad de sedentarismo detectada en la Lección 3.
4. **Monitoreo Semestral:** Utilizar este dataset como línea base para realizar estudios longitudinales que midan el impacto de estas intervenciones en el rendimiento académico y la salud mental.

8. Codebook y Github

8.1. Diccionario de Variables (Codebook)

Para garantizar la transparencia y replicabilidad de la investigación, se detalla la estructura del dataset simulado utilizado:

- **ID**: Identificador único.
- **Horas_Sueno**: Variable cuantitativa continua. Representa el promedio de horas de descanso nocturno reportadas por el estudiante.
- **Dias_Ejercicio**: Variable cuantitativa discreta. Indica la cantidad de días por semana en los que el estudiante realiza actividad física moderada o intensa.
- **Facultad**: Variable cualitativa nominal. Identifica la unidad académica de pertenencia para el proceso de muestreo estratificado.

8.2. Github

https://github.com/lalmsito/aula_digital_activities.git