

Proyecto Módulo 6: Predicción Inteligente de Gasto

Leonardo Montoya

15 de marzo de 2026

Resumen Ejecutivo

El presente proyecto entrega una solución analítica para optimizar las estrategias de marketing de la compañía mediante la predicción precisa del gasto de clientes. A través de un riguroso proceso de Machine Learning, se identificó que el **tiempo de permanencia** y la **frecuencia de visitas** son los motores que explican el **92%** del comportamiento de compra. El modelo final recomendado (Regresión Lineal con Regularización Ridge) permite estimar el ticket promedio con un margen de error de apenas **\$8.10**, ofreciendo una herramienta transparente y confiable para la toma de decisiones estratégicas.

Introducción

El presente reporte detalla el diseño e implementación de un modelo de **Machine Learning Supervisado** para el Departamento de Analítica Comercial de una empresa de e-commerce. El objetivo central es predecir el gasto promedio de los usuarios basándose en su perfil demográfico y comportamiento dentro de la plataforma, permitiendo así una personalización estratégica de las campañas de marketing.

A lo largo de este informe, se recorre el flujo de trabajo completo: desde la conceptualización del problema y la preparación rigurosa de los datos, hasta la comparación de algoritmos de alta complejidad y la optimización de hiperparámetros. El resultado final es un modelo robusto, interpretable y con una alta capacidad de generalización.

Nota sobre la Estructura del Informe

Para efectos de este proyecto, se ha optado por presentar la **Lección 3 (Preprocesamiento)** antes de la **Lección 2 (Nivel de Ajuste)**.

Esta decisión responde a una lógica técnica y operativa: para obtener métricas de ajuste confiables y ejecutar una validación cruzada efectiva, es imperativo contar con un dataset limpio y libre de valores nulos o inconsistencias. Al realizar el tratamiento de *missing values*, *outliers* y el escalamiento de variables de forma previa, garantizamos que la evaluación del modelo en la Lección 2 refleje su verdadero potencial predictivo sobre datos estructurados correctamente.

1. Lección 1: Fundamentos del Aprendizaje de Máquina

1.1. Diferenciación entre Problemas de Clasificación y Regresión

En el ámbito del aprendizaje supervisado, la distinción fundamental radica en la naturaleza de la salida:

- **Clasificación:** Se utiliza cuando la variable objetivo es categórica o discreta. El algoritmo busca asignar datos de entrada a clases específicas (ej. detección de fraude).
- **Regresión:** Se aplica cuando buscamos predecir un valor numérico continuo dentro de un rango infinito de posibilidades (ej. predicción de ingresos).

1.2. El Pipeline de un Proyecto de Machine Learning

Para garantizar la robustez del modelo, se sigue un flujo de trabajo estructurado:

1. **Definición del problema:** Identificación de objetivos de negocio y tipo de tarea.
2. **Preparación de datos:** Limpieza, imputación de nulos y normalización.
3. **EDA (Exploratory Data Analysis):** Visualización estadística para detectar sesgos.
4. **División de datos:** Separación en sets de Entrenamiento, Validación y Prueba.
5. **Entrenamiento:** Ajuste del modelo a los datos históricos.
6. **Evaluación:** Uso de métricas como RMSE o R^2 para validar la precisión.

1.3. Definición del Problema de Negocio

El requerimiento del Departamento de Analítica Comercial consiste en predecir el **monto promedio de compra** de los usuarios.

Este es un problema de **aprendizaje supervisado de regresión**. Es supervisado debido a que disponemos de datos históricos con etiquetas reales, y es de regresión porque el valor a predecir es una cantidad monetaria continua influenciada por variables demográficas y de comportamiento.

2. Lección 3: Preprocesamiento y Escalamiento de Datos

2.1. Tratamiento de Valores Faltantes y Outliers

Para asegurar la integridad del modelo, se implementó una estrategia de **imputación estadística**. Los valores numéricos faltantes se rellenaron con la media aritmética, mientras que para las variables categóricas se utilizó la moda (valor más frecuente). Respecto a

los *outliers*, se realizó un recorte (clipping) en la variable objetivo para mitigar el impacto de valores extremos que pudieran sesgar la función de pérdida del regresor.

2.2. Codificación de Variables Categóricas

Dado que los algoritmos de regresión operan sobre espacios vectoriales numéricos, se aplicó la técnica de **One-Hot Encoding** a las variables nominales (Región y Dispositivo). Este proceso transforma cada categoría única en una nueva columna binaria (0 o 1), evitando que el modelo asuma un orden jerárquico inexistente entre ellas.

2.3. Escalamiento y Normalización

Se utilizó el **StandardScaler** para estandarizar las características numéricas, transformándolas para que tengan una media de 0 y una desviación estándar de 1.

El escalamiento es crítico para que variables con rangos grandes (ej. Edad de 18 a 70) no dominen injustamente sobre variables con rangos menores durante el ajuste de los pesos del modelo. Además, se aplicó el método *fit* exclusivamente en el conjunto de entrenamiento para prevenir el **Data Leakage**, garantizando que la información del set de prueba permanezca aislada durante el proceso de aprendizaje.

2.4. Resultados del Proceso y Dimensionalidad

La ejecución del *pipeline* de preprocesamiento arrojó los siguientes cambios estructurales en el dataset:

- **Forma original de X_train:** (800, 6)
- **Forma tras transformaciones:** (800, 12)

El incremento de 6 a 12 columnas es el resultado directo de la técnica de **One-Hot Encoding** aplicada a las variables categóricas (*Dispositivo* y *Región*). Este proceso es fundamental para evitar que el algoritmo interprete categorías cualitativas como valores con un orden jerárquico artificial, permitiendo una representación matemática equitativa de cada atributo. El mantenimiento del número de filas (800) confirma que la estrategia de imputación estadística permitió conservar la totalidad de las observaciones sin recurrir a la eliminación de registros, garantizando una base de datos de alta calidad para el entrenamiento.

3. Lección 2: Nivel de Ajuste del Modelo y Validación Cruzada

3.1. Análisis de Errores y Capacidad de Generalización

Para determinar el nivel de ajuste del modelo, se evaluó el Error Absoluto Medio (MAE) en ambos conjuntos de datos. Los resultados obtenidos fueron:

- **MAE Entrenamiento:** 7.88
- **MAE Prueba:** 8.04

Se observa que la brecha entre el error de entrenamiento y el de prueba es mínima ($< 2\%$). Esto permite concluir que el modelo ha alcanzado un **ajuste óptimo**, logrando un equilibrio efectivo entre sesgo y varianza. No se detectan signos de sobreajuste (*overfitting*), ya que el modelo mantiene su precisión al enfrentarse a datos no observados previamente.

3.2. Estabilidad del Modelo mediante Validación Cruzada

Se implementó un esquema de validación cruzada de 5 subgrupos ($K = 5$) para auditar la robustez del regresor lineal. Los indicadores estadísticos resultantes fueron:

- **R^2 Promedio:** 0.9281
- **Desviación Estándar (Std):** 0.0092

El coeficiente de determinación promedio indica que las variables seleccionadas (Edad, Tiempo en Sitio, Sesiones, etc.) explican el **92.81 %** de la varianza del monto de compra. Asimismo, la bajísima desviación estándar (0.0092) confirma la **estabilidad del pipeline**: el rendimiento del modelo es consistente y no depende de una partición específica de los datos, lo que garantiza su fiabilidad para ser llevado a un entorno de producción.

4. Lección 4: Implementación y Análisis de Modelos de Regresión

4.1. Comparativa de Modelos: Simplicidad vs. Complejidad

Se contrastaron dos enfoques de aprendizaje supervisado para determinar la arquitectura óptima para predecir el gasto del cliente:

Modelo	MAE (Error Absoluto Medio)	R^2 (Coef. Determinación)
Regresión Lineal	8.04	0.9222
Regresión Polinomial (G2)	8.30	0.9183

Cuadro 1: Comparativa de rendimiento en el conjunto de prueba.

Sorprendentemente, el modelo polinomial presentó un error superior (+3,2 %) y una capacidad explicativa inferior. Esto sugiere que la estructura de los datos de e-commerce es inherentemente lineal; forzar términos cuadráticos e interacciones solo aumentó la varianza del modelo sin capturar patrones reales adicionales, incurriendo en un ligero sobreajuste. Por tanto, se selecciona la **regresión lineal** como el modelo final por su robustez y precisión.

4.2. Interpretación de Coeficientes y Hallazgos de Negocio

El análisis de los pesos (β) del modelo lineal revela los factores que realmente impulsan el monto de compra:

1. **Recurrencia (Sesiones Mensuales):** Es el predictor más potente ($\beta \approx 27,93$). Cada sesión adicional por mes incrementa el gasto esperado en casi \$28, subrayando la importancia de las estrategias de retención.

2. **Engagement (Tiempo en Sitio):** Por cada minuto adicional que un usuario navega, el monto de compra sube \$24.35. Esto valida que la optimización de la interfaz para retener al usuario tiene un impacto directo en el ticket promedio.
3. **Demografía (Edad):** Presenta un coeficiente negativo ($\beta \approx -2,52$). Esto indica que, a medida que aumenta la edad, el gasto tiende a disminuir levemente, sugiriendo que el segmento joven es el más rentable para la plataforma.
4. **Variables Categóricas (Dispositivo y Región):** Los usuarios de **Tablet** muestran una disposición al gasto ligeramente mayor ($\beta = 0,92$) en comparación con los de **Mobile** ($\beta = -0,57$). Las diferencias regionales (*Centro*, *Sur*, *Este*) tienen un impacto marginal ($< 0,17$), lo que indica que el comportamiento de compra es uniforme geográficamente.

Por lo tanto el modelo explica el **92.22 %** de la variabilidad del gasto, siendo la frecuencia de sesiones y el tiempo de permanencia las variables críticas para maximizar los ingresos de la compañía.




Figura 1: Valores Reales vs Predicciones (Regresión Lineal)

Como se observa en la Figura 1, existe una fuerte alineación entre los valores reales y las predicciones del modelo. La concentración de puntos a lo largo de la línea de identidad confirma que el regresor lineal captura con precisión la tendencia central del gasto, manteniendo una varianza controlada incluso en los montos más elevados.

5. Lección 5: Algoritmos de Clasificación y Contraste Conceptual

5.1. Inadecuación de la Clasificación para el Problema Actual

Se analizó la viabilidad de un enfoque de clasificación para predecir el gasto. Se determinó que este paradigma es subóptimo debido a:

- **Naturaleza del Target:** El monto de compra es una variable continua. La clasificación colapsa esta precisión en etiquetas discretas, perdiendo la capacidad de predecir valores exactos.
- **Pérdida de Resolución:** Al agrupar montos en rangos, el negocio pierde la capacidad de distinguir, por ejemplo, entre un cliente de \$100 y uno de \$140 si ambos caen en la categoría “Medio”.

5.2. Experimento con K-Nearest Neighbors (KNN)

Se entrenó un modelo **KNN** ($K = 5$) tras discretizar el monto de compra en tres terciles (*Bajo*, *Medio*, *Alto*). Los resultados obtenidos fueron:

Categoría	Precisión	Recall	F1-Score
Bajo	0.74	0.88	0.80
Medio	0.61	0.47	0.53
Alto	0.77	0.79	0.78

Cuadro 2: Desempeño del clasificador KNN (Exactitud Global: 71.50 %).

Análisis del Comportamiento:

1. **Sesgo en los Extremos:** El modelo identifica con relativa facilidad a los clientes de gasto “Bajo” (Recall 0.88). Esto sugiere que el perfil del comprador austero está muy bien definido en el espacio de características.
2. **Confusión en el Segmento Medio:** La categoría “Medio” presenta el rendimiento más pobre (F1: 0.53). El bajo *Recall* (0.47) indica que el modelo no logra distinguir a estos clientes, confundiéndolos frecuentemente con los de gasto bajo o alto.

Por lo tanto la comparación entre el R^2 de **0.9222** del modelo lineal y la **exactitud del 71.50 %** del KNN ratifica que la **regresión** es el camino correcto. El enfoque regresivo no solo es un 20 % más “explicativo” en términos porcentuales, sino que proporciona el valor monetario exacto necesario para las estrategias de marketing personalizado solicitadas por la empresa.

6. Lección 6: Análisis Detallado de Métricas de Desempeño

6.1. Evaluación Multidimensional del Error

Para auditar la precisión del sistema predictivo, se calcularon métricas que permiten entender tanto el error promedio como la penalización de desviaciones extremas:

Métrica	Regresión Lineal	Regresión Polinomial
MAE (Error Absoluto Medio)	8.0448	8.3037
MSE (Error Cuadrático Medio)	106.1833	111.5552
RMSE (Raíz del MSE)	10.3045	10.5620
R^2 (Coef. de Determinación)	0.9222	0.9183

Cuadro 3: Resultados comparativos en el conjunto de prueba (\$USD).

1. **Precisión Operativa (MAE):** El MAE de **8.0448** indica que, en promedio, el modelo estima el monto de compra con una desviación de apenas \$8.04 respecto al valor real. Para el ticket promedio del e-commerce, este nivel de error es insignificante, validando la utilidad comercial del modelo.
2. **Análisis de Residuos y Sensibilidad (RMSE vs. MAE):** El RMSE (**10.3045**) es ligeramente superior al MAE. Dado que el RMSE penaliza más fuertemente los errores grandes al elevar los residuos al cuadrado antes de promediar, su cercanía con el MAE sugiere que el modelo no presenta “fallos catastróficos” o *outliers* de predicción significativos que sesguen los resultados.
3. **Bondad de Ajuste (R^2):** Un coeficiente de **0.9222** significa que el **92.22 %** de la variabilidad en el gasto de los clientes es explicada por las variables de comportamiento y demografía incluidas (Sesiones, Tiempo en Sitio, Edad, etc.) [cite: 60-61].

La comparación ratifica que la **regresión lineal** es el modelo más eficiente. El modelo polinomial de grado 2 presentó un RMSE un 2.5 % mayor y un R^2 inferior, lo que evidencia que la estructura de los datos es lineal y que aumentar la complejidad solo incrementa la varianza sin mejorar la capacidad de generalización. Por lo tanto, se establece el modelo lineal como la base para la siguiente fase de optimización.




Figura 2: Distribución de Residuos

El análisis gráfico de los residuos muestra una dispersión aleatoria alrededor del eje cero, sin patrones evidentes de “embudo” o tendencias sistemáticas. Esta distribución

confirma el cumplimiento del supuesto de homocedasticidad, validando que el error del modelo es consistente a través de todos los niveles de gasto de los clientes.

7. Lección 7: Optimización del Modelo y Regularización

7.1. Estrategia de Optimización e Ingeniería de Características

Con el objetivo de “exprimir” el rendimiento del modelo y asegurar su robustez, se implementaron dos estrategias avanzadas:

1. **Feature Engineering:** Se creó la variable *Engagement_Total* (Tiempo $\times$ Sesiones). Esta interacción busca capturar el valor de los usuarios que, aunque entran poco, permanecen mucho tiempo, o viceversa, permitiendo al modelo entender comportamientos no lineales simples.
2. **Búsqueda de Hiperparámetros:** Se utilizó **GridSearchCV** con validación cruzada de 5 pliegues para encontrar la fuerza de regularización óptima (α) para un modelo **Ridge (L2)**.

En una grilla de valores (0,01 a 100), los resultados obtenidos fueron:

Parámetro / Métrica	Valor Optimizado
Mejor Alpha (Regularización Ridge)	0.01
MAE (Error Absoluto Medio)	8.1019
R ² (Coef. de Determinación)	0.9216

Cuadro 4: Desempeño del modelo tras la optimización de hiperparámetros.

Al comparar estos resultados con el modelo base de la Lección 6, se observan hallazgos técnicos clave:

- **Estabilidad vs. Precisión:** El MAE aumentó levemente de 8.04 a 8.10. Matemáticamente, el valor de $\alpha = 0,01$ indica que el modelo requiere una penalización mínima para evitar el sobreajuste. Aunque la precisión en el set de prueba bajó un 0.7%, el modelo resultante es estructuralmente más estable ante ruidos externos.
- **Selección de Modelo:** La cercanía de los resultados sugiere que el fenómeno comercial estudiado es altamente predecible mediante relaciones lineales puras. El modelo optimizado con Ridge es el preferido para producción, ya que su arquitectura previene el crecimiento desmedido de los coeficientes (β), garantizando una mejor generalización a largo plazo.

8. Lección 8: Algoritmos de Boosting y Duelo Final

8.1. Implementación de Gradient Boosting Regressor

Se implementó un modelo de **Gradient Boosting** para evaluar si un enfoque de ensamble secuencial podría capturar patrones no lineales adicionales. A diferencia del

modelo lineal, este algoritmo construye árboles de decisión de forma aditiva, donde cada nuevo árbol intenta corregir los residuos (errores) del anterior.

8.2. Comparativa Final de Modelos

Tras el entrenamiento, se realizó el contraste definitivo de métricas en el conjunto de prueba:

Modelo	MAE	R ²
Regresión Lineal (Ridge)	8.1019	0.9216
Gradient Boosting Regressor	8.2439	0.9167

Cuadro 5: Duelo final de algoritmos: Lineal vs. Boosting.

Análisis del Resultado: El modelo de Boosting presentó un error ligeramente superior (+1,7 %) y un coeficiente de determinación inferior. Este fenómeno ratifica que, para este dataset, la estructura del gasto es predominantemente lineal. La complejidad adicional del ensamble no se tradujo en una mejor generalización, reafirmando la superioridad de la parsimonia en este caso de negocio.

8.3. Importancia de Variables (Feature Importance)

El algoritmo de Boosting permitió auditar qué variables dominan la predicción del monto de compra:

- **Engagement_Total:** Representa el **90.21 %** de la importancia del modelo. Este hallazgo valida que la variable creada mediante ingeniería de características en la Lección 7 es el motor absoluto del sistema.
- **Comportamiento en Sitio:** El tiempo en minutos (5,05 %) y las sesiones (3,86 %) completan el peso predictivo, dejando a las variables demográficas y regionales con una relevancia marginal (< 1 %).

En la figura 3 se destaca la jerarquía de importancia de las variables muestra de manera contundente el dominio de la interacción “Engagement Total” sobre el resto de los atributos. Este gráfico permite visualizar por qué las estrategias de negocio deben priorizar la retención de tiempo y la frecuencia de uso, ya que estas variables concentran la mayor parte de la capacidad predictiva del sistema.

9. Conclusión y Cierre del Proyecto

Al concluir este recorrido de ocho etapas, queda claro que hemos logrado transformar un conjunto de datos brutos en una herramienta de predicción con un nivel de precisión y rigor profesional. El proceso nos permitió validar que la construcción de un pipeline de aprendizaje supervisado no se trata solo de aplicar algoritmos, sino de entender la historia que los datos intentan contar. El modelo final alcanzó una capacidad explicativa notable, logrando capturar el **92.16 %** de la variabilidad en el comportamiento de gasto de los clientes, lo que garantiza una base sólida para la toma de decisiones comerciales.




Figura 3: Importancia de Variables (Feature Importance)

A lo largo del desarrollo, el hallazgo más revelador fue descubrir que el valor de un cliente no depende de factores aislados, sino de la sinergia entre su recurrencia y su permanencia. La interacción entre el tiempo en el sitio y la frecuencia de sesiones resultó ser el motor principal del negocio, definiendo casi la totalidad del ticket promedio de compra. Este descubrimiento transforma la visión del Departamento de Analítica, permitiéndoles pasar de métricas vanidosas a una comprensión profunda de los generadores reales de ingresos.

Como paso definitivo, se propone la implementación del **modelo lineal optimizado con Ridge** como el pilar de la estrategia de marketing personalizado. Aunque se exploraron arquitecturas más complejas, este modelo demostró ser el más equilibrado, manteniendo un error promedio de apenas **\$8.10** y una estabilidad excepcional comprobada mediante validación cruzada. Su gran ventaja competitiva es la transparencia: a diferencia de los modelos de “caja negra”, esta solución permite que el equipo comercial comprenda exactamente por qué se predice un monto determinado, facilitando la creación de campañas de fidelización mucho más precisas, humanas y, sobre todo, confiables.

Recursos del Proyecto

- **Repositorio de GitHub:** Enlace al repositorio del proyecto en este se encuentran el archivo .ipynb del proyecto, debidamente documentado y comentado.