

Justificación de Decisiones Técnicas: Segmentador Inteligente de Clientes

Leonardo Montoya

18 de marzo de 2026

1. Introducción

El presente documento detalla las decisiones técnicas y metodológicas adoptadas para el desarrollo del sistema de segmentación de clientes minoristas solicitado por el Departamento de Inteligencia de Negocios de “Retail Insights S.A.”. El objetivo principal es transitar de un análisis básico hacia un modelo de aprendizaje no supervisado capaz de identificar patrones de compra ocultos y generar estrategias de marketing diferenciadas.

2. Preprocesamiento y Normalización

Dada la naturaleza heterogénea de las variables (edad, ingresos, frecuencia de compra, etc.), se aplicó un preprocesamiento basado en la normalización de los datos.

- **Decisión:** Uso de *StandardScaler* para transformar los datos a media $\mu = 0$ y desviación estándar $\sigma = 1$.
- **Justificación:** Los algoritmos de clusterización basados en distancias euclidianas son sensibles a la magnitud de las variables. Sin este paso, las variables con rangos numéricos más amplios dominarían el cálculo de similitud de forma artificial.

3. Reducción de Dimensionalidad

Para manejar la alta dimensionalidad y facilitar la visualización de los segmentos, se implementaron dos técnicas complementarias:

1. **PCA (Principal Component Analysis):** Se utilizó para proyectar los datos en un espacio de menor dimensión manteniendo la máxima varianza posible. Es fundamental para reducir el ruido y mejorar la eficiencia de los algoritmos de clusterización.
2. **t-SNE:** Se empleó específicamente para la exploración visual. A diferencia de PCA, t-SNE preserva las relaciones no lineales, permitiendo verificar si los grupos identificados mantienen una cohesión local en un entorno de baja dimensión.

4. Algoritmos de Clusterización

Se evaluaron tres enfoques distintos para asegurar la robustez de los hallazgos:

- **K-Means:** Seleccionado como modelo base por su eficiencia y capacidad de generar particiones claras. Se asume una estructura de grupos convexos para definir perfiles de clientes estables.
- **DBSCAN:** Implementado para identificar la densidad de los datos y, fundamentalmente, para la detección de *outliers* o clientes con comportamientos atípicos que no deben ser incluidos en campañas estandarizadas.
- **Agrupamiento Jerárquico:** Utilizado para validar la estructura de “parentesco” entre clientes mediante un dendrograma, lo que permite a la empresa decidir niveles de granularidad en la segmentación.

5. Evaluación y Consistencia

La determinación del número óptimo de clústeres no fue arbitraria, sino que se fundamentó en dos métricas clave:

- **Método del Codo:** Para identificar el punto donde la reducción de la inercia (suma de cuadrados internos) comienza a estabilizarse.
- **Coefficiente de Silueta:** Para medir qué tan bien separado está cada clúster de sus vecinos, asegurando que los segmentos sean distintos y accionables comercialmente.

6. Impacto Comercial

Las decisiones técnicas permiten a “Retail Insights S.A.” ejecutar campañas de retención, fidelización y ventas cruzadas basadas en datos reales y no en meras suposiciones demográficas. El código entregado es escalable, permitiendo la incorporación de nuevos datos de forma eficiente.