

Proyecto: Segmentador Inteligente de Clientes Minoristas

Módulo 7: Aprendizaje de Máquina No Supervisado

Leonardo Montoya

18 de marzo de 2026

1. Lección 1: Fundamentos del Aprendizaje No Supervisado

1.1. Principales tareas del Aprendizaje No Supervisado

El aprendizaje no supervisado busca identificar patrones, estructuras o relaciones ocultas en conjuntos de datos que no poseen etiquetas previas. Sus tareas principales incluyen:

- **Descubrimiento de estructuras:** Identificar cómo se agrupan los datos de forma natural.
- **Reducción de ruido:** Simplificar los datos eliminando variables redundantes.
- **Detección de anomalías:** Identificar puntos de datos que se desvían significativamente del comportamiento normal.

1.2. Clasificación de Técnicas

Las técnicas de aprendizaje no supervisado se clasifican generalmente en tres categorías:

1. **Clusterización (Agrupamiento):** Divide los datos en grupos con características similares (ej. K-Means, DBSCAN).
2. **Reducción de Dimensionalidad:** Proyecta datos de alta dimensión en espacios más pequeños preservando la información relevante (ej. PCA, t-SNE).
3. **Asociación:** Descubre reglas que describen grandes porciones de los datos, como “si un cliente compra A, suele comprar B”.

1.3. Casos Reales de Aplicación

- **Segmentación de mercado:** Agrupar clientes por comportamiento de compra para marketing personalizado.
- **Biología:** Clasificación de genes con patrones de expresión similares.
- **Compresión de imágenes:** Reducción del número de colores o dimensiones sin perder la esencia visual.

2. Lección 2: Técnicas de Clusterización

2.1. Escenarios de Aplicación

La clusterización es ideal en situaciones donde no se conoce de antemano la categoría de los datos:

- **Retail:** Identificación de perfiles de clientes basados en frecuencia y monto de compra.
- **Seguridad:** Agrupamiento de registros de red para detectar intrusiones o comportamientos inusuales.
- **Sistemas de recomendación:** Agrupar productos similares para sugerirlos a usuarios con gustos afines.

Ventajas	Desventajas
No requiere datos etiquetados (menor costo).	La interpretación de los clústeres es subjetiva.
Revela patrones que los humanos podrían ignorar.	Sensible a la escala de los datos y <i>outliers</i> .
Escalable a grandes volúmenes de datos.	Difícil de evaluar sin una métrica de “verdad”.

2.2. Ventajas y Desventajas

2.3. Comparativa de Algoritmos

Característica	K-Means	DBSCAN	Jerárquico
Tipo de grupo	Esférico y definido	Basado en densidad	Estructura de árbol
Sensibilidad a Ruido	Alta (afecta centroides)	Baja (detecta <i>outliers</i>)	Media
Parámetros clave	Número de clústeres (K)	Radio (ϵ) y MinPts	Criterio de enlace
Forma del clúster	Convexa	Arbitraria	Cualquier forma

2.4. Asociación de Algoritmos a Problemas Reales

- **K-Means:** Ideal para segmentación de clientes cuando se espera que los grupos tengan tamaños similares y formas circulares.
- **DBSCAN:** Recomendado para datos espaciales o geográficos donde los grupos tienen formas irregulares y hay mucho ruido.
- **Agrupamiento Jerárquico:** Útil en taxonomía o cuando se desea visualizar la relación de “parentesco” entre grupos mediante dendrogramas.

3. Lección 3: Reducción Dimensional y Preprocesamiento

3.1. Objetivo y Preparación de Datos

El objetivo primordial de esta etapa es aplicar técnicas de reducción de dimensionalidad como PCA y t-SNE para simplificar el análisis de datos de clientes. Antes del modelado, se procedió a limpiar y preprocesar el dataset mediante técnicas de normalización, asegurando que variables con distintas escalas (como edad e ingresos) no sesguen el comportamiento de los algoritmos.

3.2. Implementación de PCA y t-SNE

Siguiendo los requerimientos técnicos, se implementaron dos metodologías utilizando la librería *scikit-learn*:

1. **PCA (Principal Component Analysis):** Una técnica lineal para reducir la dimensión preservando la mayor varianza posible.
2. **t-SNE (t-distributed Stochastic Neighbor Embedding):** Una técnica no lineal diseñada específicamente para la visualización de estructuras complejas en espacios de baja dimensión.

3.3. Visualización y Comparación de Resultados

Tras la reducción a dos dimensiones, se generaron las visualizaciones correspondientes para analizar visualmente la distribución de los clientes.




Figura 1: Comparativa entre la reducción lineal (PCA) y no lineal (t-SNE). Mientras PCA muestra una dispersión basada en la varianza global, t-SNE intenta agrupar vecindades locales para revelar patrones ocultos.

Se ha determinado que para el problema actual de Retail Insights S.A., ambas técnicas son necesarias:

- PCA es fundamental para el pre-procesamiento previo a la clusterización, ya que reduce el ruido y mejora el rendimiento computacional.
- t-SNE es la herramienta óptima para la comunicación de resultados, permitiendo presentar *insights* visualmente entendibles sobre los segmentos identificados.

4. Lección 4: Aplicación Práctica y Evaluación

4.1. Análisis de Métricas de Selección

Como se observa en la Figura 1, se aplicó el método del codo y el coeficiente de silueta. Aunque la inercia decrece linealmente, el coeficiente de silueta revela que las estructuras de 6 y 8 clústeres ofrecen mayor cohesión. No obstante, para mantener la interpretabilidad comercial solicitada por Retail Insights S.A., se analizó la viabilidad de 4 segmentos principales.




Figura 2: Evaluación de métricas: Relación entre Inercia (Codo) y Silhouette Score para determinar el valor de K.

4.2. Visualización Comparativa de Segmentación

La Figura 2 muestra la proyección de los algoritmos sobre los componentes de PCA. Se destaca que:

- **K-Means** y **Jerárquico** ofrecen una segmentación equilibrada y accionable.
- **DBSCAN** no logró separar grupos significativos, indicando que el dataset no presenta vacíos de densidad claros.




Figura 3: Visualización 2D de los clústeres formados por K-Means, DBSCAN y Agrupamiento Jerárquico.

4.3. Validación mediante Dendrograma

Para confirmar la jerarquía de los clientes, se generó el dendrograma (Figura 3). El corte horizontal confirma la existencia de 4 a 7 perfiles diferenciados por distancias euclidianas significativas.




Figura 4: Dendrograma de clientes: Estructura jerárquica basada en distancias euclidianas.

5. Lección 5: Evaluación e Informe de Resultados

5.1. Comparativa de Segmentaciones Generadas

Tras implementar tres metodologías distintas, se realizó una evaluación comparativa para determinar la robustez de los grupos identificados:

- **K-Means vs. Agrupamiento Jerárquico:** Ambos algoritmos mostraron una alta consistencia en la asignación de individuos a los 4 clústeres principales. La estructura radial de K-Means facilitó la definición de fronteras comerciales claras, mientras que el enfoque jerárquico validó la existencia de subgrupos internos mediante el dendrograma.
- **Análisis de DBSCAN:** A diferencia de los anteriores, DBSCAN identificó una densa masa central. Esto sugiere que la mayoría de los clientes comparten comportamientos base, y las diferencias se encuentran en las magnitudes de gasto y frecuencia más que en la densidad de los puntos.

5.2. Evaluación de la Consistencia

La validez del modelo se sustenta en tres pilares técnicos:

1. **Estabilidad Matemática:** El Coeficiente de Silueta para $K = 4$ presenta valores positivos y consistentes, indicando que los clientes están más cerca de su propio centroide que de los vecinos.
2. **Representación Dimensional:** La proyección en PCA y t-SNE permite confirmar visualmente que no existen solapamientos excesivos que invaliden la segmentación.
3. **Coherencia de Negocio:** Los segmentos resultantes son de tamaños suficientes para ser sujetos de campañas de marketing independientes.

5.3. Sugerencias y Usos Comerciales

A partir de los grupos identificados, se proponen las siguientes estrategias de negocio para el cliente:

Segmento	Perfil Identificado	Estrategia Recomendada
Clúster 1	Clientes VIP (Alto gasto/Frecuencia)	Programas de fidelidad y acceso exclusivo.
Clúster 2	Clientes Ocasionales de Gran Volumen	Campañas de <i>cross-selling</i> y recordatorios.
Clúster 3	Jóvenes con Potencial de Crecimiento	Ofertas digitales y descuentos por frecuencia.
Clúster 4	Clientes en Riesgo (Baja actividad)	Campañas de reactivación con incentivos agresivos.

Cuadro 1: Matriz de segmentación y acciones estratégicas para Retail Insights S.A.

5.4. Conclusiones Finales

El sistema de segmentación inteligente desarrollado permite a la consultora pasar de una visión demográfica básica a una basada en patrones ocultos de comportamiento. La escalabilidad del pipeline en Python asegura que el modelo pueda ser re-entrenado conforme el dataset de clientes crezca en el futuro.